

선반에서 기계학습을 통해 공구 마모 진단 및 예측을 위한 빅데이터 분석 장치 개발

Development of a Big Data Analysis Device for Tool Wear Diagnosis and Prediction through Machine Learning on Lathes

정석준¹, 정승원¹, 한태연¹
Seok Jun Jeong¹, Seung Won Jeong¹, and Tae Yeon Han¹

¹ 홍익대학교 기계시스템디자인공학과 (Department of Mechanical and System Design Engineering, Hongik University)

KEYWORDS: Machine Learning (머신러닝), Tool wear diagnosis (공구 마모 진단), Sensor fusion (센서 퓨전), Lathe (선반), Piezo sensor (피에조 센서), Microphone(마이크로폰)

실무에서 진행되는 선반 가공 공정은 제품 하나를 완성하기 위해 다양한 가공 조건이 필요하다. 이는 수많은 선행 연구 결과들의 현업에서의 적용을 어렵게 만드는 주요 요인 중 하나이다. 또한, 시중에 판매되는 다양한 마모 진단 기기는 고가이며, 기존에 사용하던 머신과의 호환성 문제로 현업 종사자들이 이용하기 쉽지 않다. 본 연구에서는 선반 가공 공정의 공구 마모 진단을 위한 저비용 모듈을 개발했다. 피에조 센서와 마이크로폰을 사용하여 진동과 소음 신호를 수집하고, 이를 XGBoost 모델을 사용하여 머신러닝 분석하였다. 개발된 모듈은 95.8%의 공구 마모 진단 정확도를 달성했으며, 기존의 제약을 극복하여 중소형 가공 업체의 생산 효율성을 향상시키는 가능성을 제시한다.

NOMENCLATURE

m = mass
 c = damping coefficient
 k = spring coefficient
 ΔS = thickness of chip
 Δr = variation in feed rate
 f = cutting force

1. 서론

공구 마모의 진단과 예측을 통한 적절한 시기의 교체는 가공의 생산 효율 향상과 직결되어 있다. 여러 진단 기기가 시중에 판매 중이며, 현재도 공구 마모 진단을 위한 연구가 활발히 진행되고 있다[1]. 하지만 이러한 진단 기기의 적용은 비용적 부담이 상당할 뿐만 아니라, 기존에 사용 중이던 선반과의 호환성 등 많은

제약이 따른다. 또한, 현업에서 이뤄지는 선반 공정은 하나의 제품을 완성하기 위해 서로 다른 가공 조건으로 구성된 일련의 가공이 진행되기에 진단 기기의 실질적인 사용이 어려운 실정이다.

본 연구에서는 이러한 한계점을 극복하기 위해 AE(Acoustic emission)센서의 원리를 이용한 저비용의 진동 센서와 마이크로폰을 사용하여 간편한 부착 방식의 데이터 수집 모듈을 제작한다. 수집된 데이터는 모듈 내부의 싱글 보드 컴퓨터에서 공구의 마모 진단을 위한 머신 러닝 모델의 학습에 사용되며, 학습된 알고리즘을 이용해 복합적인 가공 조건으로 구성된 공정에서도 공구 마모 진단이 가능함을 보이는 것을 목표로 한다.

2. 센서 선정

선반에서는 절삭력 변화에 따라 Regenerative chatter가 발생한다. 칩의 두께는 이 chatter의 주된 변수 중 하나이며[2], 본 연구에서는 발생하는 진동을 측정하기 위해 가속도계를 사용했다.

$$m\ddot{x} + c\dot{x} + kx = -f(\Delta s, \Delta r)$$

또한, 현지 생산업체 종사자의 인터뷰를 바탕으로 소음을 이용하여 공구의 마모 진단이 가능함을 확인한바, 마이크로폰을 동시에 활용해 마모를 진단하고자 했다. 따라서 본 연구에서는 고성능 센서를 이용해, 진동과 소음으로 공구의 마모 진단 가능 여부를 판단하고, 저가의 센서를 이용한 마모 진단 모듈을 제작하여 진단 기능을 구현하고자 한다.

해당 모듈에는 피에조 센서와 저가형 마이크로폰을 사용했다. 피에조 센서는 P 파, S 파 등의 파동을 수집하기에 유리하다. 또한, 관성의 영향을 받지 않고 진동 측정이 가능하기에, 적은 비용으로 가속도계를 대신하여 기능을 수행할 수 있다.

이에 2.1 장에서, Piezo electrical material 을 사용하는 AE 센서의 원리와 본 연구에서 제시하는 피에조 센서 모델을 함께 설명했다. 이후, 2.2 장에서는 개발한 피에조 센서 모듈과 저가형 마이크로폰의 성능에 대해 신뢰성을 검증하는 내용을 서술한다.

공구의 마모 판단 기준은 여유 면의 평균 마모 폭이 0.3mm 이상인 경우나 최대 마모 폭이 0.5mm 이상인 경우로 하였다[3].

Table 1 Experimental equipment

Setup	Sensor	Model
Lathe	HL-380	DAQ
Insert	Carbide	Accelerometer
Workpiece	S45C	Microphone
-	-	Piezo sensor
-	-	Microphone




Fig.1 Turning insert (a) normal, top surface (b)wear, top surface (c) wear, side surface

2.1. Piezo Sensor

AE 센서는 Piezo material 에서 발생하는 전기적 신호를 기반으로 다양한 형태의 파동 신호를 수집하는 데에 유리하다. Piezo material 은 진동으로 인해 압축되며 전압을 발생시키고, 공급되는 전압으로 팽창을 반복하며 진동을 측정한다. 본 연구에서는 피에조 센서 DFR0052 를 이용하여 AE 센서의 원리를 구현하고, 기기 자체의

하중과 자기력을 이용해 반응 시간을 최소화했다. 또한, 저가형 피에조 센서는, 파동의 전달 반사에 취약하기에 부직포를 Damping material 으로 사용함으로써 보완했다.




Fig.2 (a) Free body diagram, (b) AE and Piezo sensor structure

2.2 저가형 센서 마모 진단 성능 검증

Fig.3, 4 는 고성능 가속도계 AC214-1D 와 마이크로폰 CRY333-T1 으로 실험한 결과이다. 먼저, 가속도계를 이용한 진동 데이터 수집 결과, 5kHz~6kHz 영역대에서 Magnitude 5000 이상의 값이 정상 공구에 비해 마모 공구에서 더 많이 발생함을 알 수 있다. Fig.3(a), (b)는 각각 정상, 마모 공구를 이용해 수집한 데이터의 FFT(Fast Fourier Transform) 분석 결과이고, Fig.3(c)는 언급된 영역대에서 Magnitude 5000 이상인 주파수의 Magnitude 합을 표현한 Histogram 으로, 마모 공구 데이터의 평균값이 정상 공구의 평균보다 약 1.3 배 높음을 알 수 있다.




Fig.3 Accelerometer data (a) normal insert, (b) wear insert, (c) comparison

소음은 정상 공구에 비해 마모 공구에서 10~15kHz 영역대의 Magnitude 120 이상의 값이 더 많이 수집되었다. Fig.4(a), (b)는 정상과 마모 공구를 이용해 수집한 데이터의 FFT 분석 결과이고, Fig.4(c)는 Magnitude 120 이상인 주파수의 Magnitude 합을 표현한 Histogram 이다.




Fig.4 Microphone data (a) normal insert, (b) wear insert, (c) comparison

고성능 센서를 통해 얻은 결과인 Fig.3, 4 로 미루어 보아, 저가형 센서인 DFR0052, GY-MAX9814 로 수집한 데이터에서도 진동은 5~6kHz 에서, 소음은 10~15kHz 에서 정상과 마모 공구 간 차이가 발생할 것이라 예상했다. Fig.5, 6 은 저가형 센서로 정상과 마모 공구를 이용해 수집한 데이터를 이전과 동일한 방식으로 FFT 분석 결과와 Histogram 을 표현한 것이다. 이를 통해 저가형 센서 또한 고성능 센서와 동일하게 특정한 주파수 영역대에서 공구의 상태에 따른 차이가 나타났음을 알 수 있다.




Fig.5 Piezo sensor data (a) normal insert, (b) wear insert, (c) comparison




Fig.6 Microphone data (a) normal insert, (b) wear insert, (c) comparison

한편, Fig.2(c), 3(c), 4(c), 5(c)을 보면, 각 공구의 1 차 실험에서 진동과 소음이 유독 크게 수집되었는데, 이는 첫 번째 가공 이후 Insert 의 온도가 증가했기 때문으로 보인다. 공구 및 시편의 온도를 완벽히 통제하여 실험을 하지는 못했으나, 1 차 이후의 실험에서 또한 마모 공구의 데이터가 정상 공구의 데이터에 비해 높음을 확인했다.

2.4 저가형 센서 신뢰도 검증

2.4.1 센서의 신뢰도 검증 실험 결과

저가형 센서는 동일 조건의 가공에 대해 일관된 데이터가 수집되며, 고성능 센서의 데이터와 동일한 결과 값을 가질 때 신뢰성이 있다고 볼 수 있다. 이를 확인하기 위해 DAQ(NX-9775)를 사용하여 가속도계와 피에조 센서로 진동 데이터를 초당 Sample 20k 개, 고성능, 저가형 마이크로폰으로 소음 데이터를 초당 Sample 40k 개씩 각각 4 회 데이터 수집을 진행했다. 수집된 데이터를 이용하여 공구의 상태에 따라 차이가 발생했던 주파수

영역대에서 센서별로 첨도와 왜도를 구하고, 각각의 평균과 표준편차를 Table 2 에 기재하였다.



Fig.7 Summary of signal acquisition and data path with DAQ

Table 2 Kurtosis and Skewness of each sensor

	Kurtosis		Skewness	
	Mean	Std	Mean	Std
ACC(5~6kHz)	3.33	0.54	1.65	0.07
Piezo(5~6kHz)	2.31	1.14	1.14	0.31
Mic_H(10~15kHz)	2.19	1.11	0.99	0.17
Mic_L(10~15kHz)	1.58	0.59	1.06	0.13

ACC: AC214-1D / Piezo: DFR0052

Mic_H: CRY333-T1 / Mic_L: GY-MAX9814

2.4.2 통계적 특성 분석 결과

첨도의 평균이 3 에 가깝고 고성능 센서와 저가형 센서의 차이가 작을수록, 또한 첨도와 왜도의 표준편차가 작을수록 데이터가 일관되게 수집되었음을 의미한다. Table 2 의 결과값을 보면, 진동과 소음 데이터에서 모두 고성능 센서가 저가형 센서보다 더욱 정밀하고 일관된 데이터를 수집하였음을 알 수 있다. 하지만 이는 고성능 센서와의 상대적인 비교이다. 실제로는 저가형 센서가 수집한 데이터의 왜도와 첨도의 평균, 표준편차 값은 수집된 데이터가 일관적이고 고성능 센서들과 매우 유사한 결과를 내었음을 의미한다. 즉, 저가형 센서인 DFR0052 와 GY-MAX9814 는 위 4 회 실험에 대해 반복적이고 일관된 데이터 수집으로 정상과 마모 공구를 구분하는데 신뢰도가 있다고 판단할 수 있다.

3. 데이터 수집

대부분의 선반 공정은 단순 가공의 반복보다는 다양한 조건의 가공이 연속적으로 진행된다. 가공 조건이 변화함에 따라 발생하는 신호 또한 달라지기 때문에, 단일 조건에서 발생하는 신호를 수집하고 분석하는 것만으로는 현장에서의 적용이 어렵다고 생각된다. 따라서, 본 연구에서는 공구 마모 진단 머신러닝 모델 개발에 앞서서 여러 가공 조건이 복합적으로 조합되어 진행되는 일련의 가공 과정을 구현하기 위해, 이송

속도와 절삭 깊이에 변화를 주는 가성의 공정(이하 시퀀스)을 설계하였다.

데이터 수집을 위한 모듈에는 앞서 선정된 DFR0052 피에조 센서와 GY-MAX9814 마이크로폰이 부착되었으며, DAQ 를 대신하여 데이터 수집과 연산이 용이한 Raspberry pi 4B 가 사용되었다. 피에조 센서는 기계의 진동을 직접적으로 수집할 수 있도록 모듈의 바닥에 위치시켰고, 마이크로폰은 모듈 벽면에 구멍을 뚫어 보다 효과적으로 수음할 수 있도록 설계하였다. 모듈의 부착 위치는 칩의 영향을 비교적 적게 받는 Tool slide 로 하였으며, 자석을 이용해 쉬운 탈부착이 가능하게 했다.




Fig.8 Summary of signal acquisition and data path with produced module




Fig.9 Data collection with the produced module

다만, Raspberry pi 는 센서별로 초당 샘플을 6000 개까지만 동시에 수집할 수 있다는 한계가 있었다. 즉, 데이터 수집을 위해 제작한 모듈로는 3kHz 까지의 데이터만을 받을 수 있으며, 해당 주파수 영역대에서 공구 상태에 따른 신호의 차이가 있어야 마모 진단이 가능함을 의미한다. 모듈의 사용 가능 여부를 확인하기 위해 정상 공구와 마모 공구를 이용하여 4 차례씩 데이터를 수집했다. 수집한 데이터는 앞서 저가형 센서의 마모 진단 성능 검증 때와 동일한 방식으로 FFT 분석 결과와 특정 Magnitude 이상인 주파수의 Magnitude 합을 표현한 Histogram 을 Fig.10, 11 로 나타내었다. 그 결과 Piezo 센서는 2~3kHz 영역에서, 마이크로폰은 1~2kHz 영역에서 차이가 발생했다. Piezo 센서는 마모에서 진폭이 더 컸고, 마이크로폰은 정상에서 진폭이 더 컸다. 이러한 결과를 바탕으로, 제작한 모듈을 이용하여 공구의 마모 진단이 가능함을 확인할 수 있었다.




Fig.10 Piezo sensor 2kHz to 3kHz




Fig.11 Mic sensor 2kHz to 3kHz

데이터 수집을 위한 시퀀스는 이송속도와 절삭 깊이가 변하는 3 번의 공정으로 구성했으며 각 공정의 가공조건은 Table 3 와 같다.

Table 3 Processing conditions of the sequence experiment

	Spindle speed(rpm)	Feed rate(mm/rev)	Depth of cut(mm)	Length (mm)
1 st	900	0.33	2	25
2 nd	900	0.24	2	20
3 rd	900	0.24	3	15

Insert: Carbide

Workpiece: S45C




Fig.12 Sequence experiment (a) Schema, (b) Sequence process

4. 데이터 분석

4.1 전처리 과정

공구 마모 진단을 위한 머신러닝(이하 ML) 모델의 학습을 위한 데이터는 앞서 설계한 시퀀스를 정상 공구로 32 회, 마모 공구로 20 회로, 총 156 회의 행정으로 가공하여 수집되었다. 수집된 156 개의 데이터 파일은 각각 아래의 데이터 전처리 과정을 거쳐 156 행, 6 열의 데이터 시트로 변환되었다.

주파수 도메인은 신호의 주파수 성분들이 분리되어 표현하기에 선형적인 패턴 감지에 유리하다. 그러나 선반 가공에는 데이터 분석 결과에 영향을 미칠 수 있는 수많은 변수가 존재하며, 본 연구에서 다루고자 하는 기계의 진동, 소음 데이터는 외부 요인들에 광장히 취약하다. 이처럼 여러 요인이 복합적으로 작용하는 데이터를 분석하는 경우, 비선형적 패턴 및 관계를 다루기 쉬운 시계열 도메인에서의 분석이 이점을 갖는다.

그러나 저가형 센서의 경우 고성능 센서에 비해 노이즈가 많이 발생하기 때문에 이를 제거하는 과정이 필요하다. 따라서, 본 연구에서는 시퀀스 가공 실험을 통해 수집된 데이터를 분석하기에 앞서, Frequency domain 에서 정상과 마모의 차이가 두드러지지 않는 주파수 영역의 노이즈를 제거한 뒤, IFFT(Inverse Fast Fourier Transform)을 통해 시간 도메인으로 재변환했다. 다만, 이 과정에서 발생하게 되는 복소수는 이후 진행할 Standard scaling 과 PCA 에서 사용되는 Scikit-learn 의 패키지에서 지원하지 않는 형식이기에 허수부를 제거하였다.

$$Scaled\ data = (raw\ data - avg)/std$$

실수부만 남은 시계열 데이터는 위 식을 따라 표준화된다. 데이터를 표준화하는 Standard scaling 은 각 데이터를 정규 분포로 스케일을 일치시켜 서로의 특성을 비교하는데 이점이 있으며, 이는 머신 러닝 알고리즘의 모델링 및 예측을 수월하게 만든다.

정상과 마모 공구의 데이터를 구별하는 ML 알고리즘 모델의 학습에는 각 데이터를 대표하는 통계적 특성이 이용되었으며, 사용한 통계적 특성은 최솟값, 최댓값, 분위 수, 중간값, 왜도, 첨도이다. (scaling 을 통해 표준화된 데이터이므로 평균과 표준편차, 분산은 고려하지 않았다.)

	min	max	quantile	median	skew	kurtosis
np_1_1	-1.35	45.01	-0.02	-0.02	32.24	1390.16
np_1_2	-1.47	47.26	-0.03	-0.03	35.84	1668.44
...
wp_20_2	-1.57	48.72	-0.03	-0.03	39.27	1885.20
wp_20_3	-1.19	48.38	-0.02	-0.02	38.83	1838.58

(a) Piezo sensor data

	min	max	quantile	median	skew	kurtosis
nm_1_1	-4.97	49.54	-0.01	-0.01	40.46	2008.87
nm_1_2	-4.34	49.89	-0.02	-0.02	41.34	2066.19
...
wm_20_2	-3.49	49.45	-0.01	-0.01	40.25	1994.11
wm_20_3	-4.14	49.89	-0.00	-0.00	41.33	2066.23

(b) Mic sensor data

Fig.13 Statistical characteristics data sheet

PCA(Principal Component Analysis)는 다차원 데이터의 불필요한 정보를 제거하거나 주요 특징을 보존하면서 차원을 줄여 데이터를 요약하는 분석법이다. 본 연구에서는 앞선 복소수의 허수부 제거 이후, 추가적인 데이터의 손실을 막기 위해 주요 성분으로써 남길 차원의 개수를 통계적 특성의 수와 동일하게 6 개 차원으로 설정하였다. 이로써 차원을 축소하지는 않았지만, 데이터의 주요 특성을 부각해 ML 알고리즘 모델이 주요 패턴과 정보를 학습하는 데 도움이 되도록 하였다.

공구의 상태에 따른 데이터를 구별 및 진단하기 위해 Classification 계열의 알고리즘을 사용하였다. 사용된 ML 모델은 Logistic Regression(이하 LR), Support Vector Machine(이하 SVC), Random Forest(이하 RF), XGBoost 이며, Piezo 센서의 데이터와 Mic 센서의 데이터에서 각각 가장 좋은 성능을 보이는 모델을 모듈 탑재용으로 선택했다. 모델의 학습과 평가는 시퀀스 가공 실험을 통해 수집된 52 번의 시퀀스 데이터를 이용했다. 이 중 75%는 모델의 학습용으로, 25%는 평가용으로 나누어 사용되었다.

4.2.1 평가 결과

Table 4 Evaluation of piezo sensor machine learning model

Piezo	LR	SVC	RF	XGBoost
Accuracy	0.872	0.821	0.872	0.897
Precision	0.874	0.823	0.871	0.897
Recall	0.872	0.821	0.872	0.897

Table 5 Evaluation of microphone machine learning model

Piezo	LR	SVC	RF	XGBoost
Accuracy	0.744	0.667	0.718	0.744
Precision	0.741	0.583	0.720	0.745
Recall	0.744	0.667	0.718	0.745

Classification 계열의 모델을 평가하는 주 3 요소인 정확도, 정밀도, 재현율을 고려했을 때, Piezo 센서와 Mic 센서의 데이터에서 모두 XGBoost 의 성능이 가장

우수함을 Table 4.5 를 통해 알 수 있다. 더 나아가, 본 연구의 목적인 공구의 마모를 사전에 예측 및 진단하여 불필요한 공구 교체를 줄여 생산 효율을 높이는 것을 고려했을 때, 정밀도 값이 가장 높은 모델인 XGBoost 를 모듈에 탑재하는 것이 타당하다고 보인다.

4.2.2 진단 기준

기본적인 진단 방법으로써, 모델의 출력값이 0.5 이하면 0(정상)으로, 0.5 이상이면 1(마모)로 클래스를 나누어 진단하였다. 그러나, 공구의 상태를 진단하는 ML 알고리즘 모델이 센서 개별로 존재하기에, 두 모델이 서로 다른 진단 결과를 내는 경우가 발생할 수 있다. 이때, 본 연구에서는 이진 분류를 하는 Classification 계열의 ML 모델은 결과의 출력 기준으로 threshold(임계값, 0.5 로 설정)를 사용한다는 점을 이용하였다. 즉, 각 모델에서 출력한 값이 threshold 와의 차이를 기준으로, 그 크기가 더 큰 값을 갖는 모델의 진단 결과를 따랐다. 그 과정을 수식으로 나타내면 다음과 같다.

$$Result = \text{Max}(|\text{Piezo-threshold}|, |\text{Mic-threshold}|)$$

	Piezo	Mic	Result	ANSWER		Piezo	Mic	Result	ANSWER
0	0.000696	0.006401	Normal	Normal	35	0.982993	0.009578	Normal	Wear
1	0.000481	0.002951	Normal	Normal	36	0.997448	0.655621	Wear	Wear
...
28	0.057890	0.012404	Normal	Normal	45	0.892865	0.985826	Wear	Wear
29	0.604870	0.886052	Wear	Normal	46	0.823351	0.993709	Wear	Wear
30	0.993273	0.929652	Wear	Wear	47	0.940298	0.980428	Wear	Wear

Fig.14 Using two ML models for diagnostic criteria

예를 들어, Fig.14 의 35 열의 경우 피에조 센서의 모델은 정상, 마이크로폰의 모델은 마모로 진단하였다. 진단 기준에 따르면, 마이크로폰 모델의 출력값의 0.5 와의 차이의 크기가 피에조 센서보다 크므로, 마이크로폰 모델의 진단 결과에 따라 정상 진단이 내려지게 된다.

5. 연구 결과

Piezo 센서와 Mic 센서의 데이터를 이용하여 ML 모델을 학습 및 평가한 결과, 두 센서에서 모두 XGBoost 알고리즘이 선택되었으며, 두 알고리즘을 이용한 진단 기준까지 준비하여 앞서 만들어 둔 모듈에 탑재시켰다.




Fig.15 Diagnosis result scatter plot (a) Piezo sensor (b) Microphone

이 모듈을 부착시킨 선반으로 임의의 시퀀스 가공을 진행하였고, 모듈이 수집된 데이터를 자체적으로 처리하여 공구의 마모 진단을 해내는 것을 확인하였다. 해당 시퀀스 실험은 정상 10 회, 마모 6 회로 진행되었다. 16 회의 시퀀스로 총 48 회의 테스트 결과, Piezo 센서와 Mic 센서의 모델이 동일한 진단을 하여 공구의 상태를 마친 것뿐만 아니라, 서로 다른 진단을 한 경우에도 앞서 언급한 진단 기준에 따라 최종적으로 전체 48 회 중 단 2 개의 오답을 내어 95.8%의 진단 정확성을 내었다.

6. 결론

공구의 마모 진단을 위한 연구는 활발히 진행되어 왔다. 하지만, 현업에서 이뤄지는 선반 공정은 하나의 제품을 완성하기까지 다양한 가공 조건으로 구성된 공정을 거치며, 이는 연구 결과의 적용을 어렵게 만든다. 또한, 시중의 다양한 마모 진단 기기는 비용뿐만 아니라, 기존에 사용하던 머신과의 호환성 등 상당한 제약이 존재한다. 본 연구에서는 이러한 한계점을 극복하기 위해, 데이터 수집 및 공구 마모 진단을 위한 ML 모델이 탑재된 모듈의 개발을 목표로 하였다. 모듈에 사용될 적절한 저가형 센서로 피에조 센서와 마이크로폰이 사용되었으며, 이 센서들의 적합 여부를 공구 마모 진단 실험과 신뢰도 검증 실험을 통해 확인하였다. 선정된 센서를 이용해 임의로 설계한 시퀀스 공정에서 진동 및 소음 신호를 수집하였고, 수집된 데이터로 Classification 계열의 XGBoost 모델을 학습시켰다. 이후, 학습된 모듈을 모듈에 적용하여 성능 검증 실험을 통해, 저가형 공구 마모 진단 모듈의 효용을 확인할 수 있었다. 본 연구에서는 제작한 모듈을 활용하여 진단 정확도를 95.8%까지 달성함으로써, 저비용의 장치로도 공구 마모 진단이 가능함을 입증했다. 다만, Single board computer 로 사용된 Raspberry pi 의 연결 불안정성과 모델 학습을 위한 데이터의 부족으로 인한 과적합(overfitting), 칩으로 인한 모듈의 손상은 해결해야 할 문제이며, 임의로 구성한 시퀀스에서 Spindle speed 의 변화는 주어지지 않았으므로 후속 연구가 필요하다.

사용된 센서와 장치는 범용 제품으로, 전용 보드와 센서를 개발한다면 모듈의 크기를 더욱 소형화할 수 있다. 또한, 충분한 데이터 수집을 통해 기계 학습 모델의 학습을 강화하면, 더 뛰어난 성능의 마모 진단 장치를 개발할 수 있을 것으로 기대된다. 이러한 정확성 개선과 소형화를 통해 기존에 시장에서 판매되는 진단 장비의 한계를 극복하고, 중소기업의 가공 업체의 생산 효율성 향상에 기여할 수 있는 가능성을 시사한다.

ACKNOWLEDGEMENT

센서의 선정부터 데이터 수집, 전송 및 분석까지의 모든 과정은 처음부터 끝까지 공부가 필요했습니다. 지식을 습득하고 실무에 적용하면서 여러 시행착오가 있었지만, 모든 과정이 어디서든 얻을 수 없는 소중한 경험이자 성장의 과정이었습니다. 이번 정밀공학 창의경진대회를 통해 저희에게 좋은 경험을 제공해 주신 한국 정밀공학회 운영진과 관계자분들에게 진심으로 감사드리며, 항상 끝까지 포기하지 않도록 독려해 주신 지도 교수님께도 감사의 말씀을 드립니다.

REFERENCES

1. Munaro R, Attanasio A, Del Prete A, Tool Wear Monitoring with Artificial Intelligence Methods: A Review, Journal of Manufacturing and Materials Processing7, No.4, 129, 2023
2. Naren Deshpande, M.S.Fofana, Nonlinear Regenerative Chatter in Turning, Robotics and Computer Integrated Manufacturing Vol.17, Issues1-2, 107-112, 2001
3. Jeong Han Ko, Young Tae Kim, Sang Jo Lee, Research about Tool Wear Monitoring in CNC Lathe Machining(1), Journal of the Korean Society of Precision Engineering, Vol.17, No.12, 54-60, 2000

APPENDIX

A1. 고성능 장치와 저비용 장비의 가격 비교

Table 6 BOM for the High-performance devices

	Model	Price
AE Sensor	AE Sensor/R15a	4,900,000
Microphone	CRY333-T1	1,170,000
DAQ	NX 9775	6,178,680
Total Price		12,248,680

Table 7 BOM for the Low-price devices

	Model	Price
Piezo Sensor	DFR0052	5,390
Microphone	GY-MAX9814	3,700
Board	Raspberry Pi 4B	68,000
ADC	MCP3008	2,870
Magnet	Neodymium magnet	15,100
3D Printing	Case	94,710
Total Price		189,770



Seok Jun Jeong

B.Sc. candidate in the Department of Mechanical and System Engineering, Hongik University.

His research interest is

AI, Big Data, Machine Learning

E-mail: wjdtjrwns97@naver.com



Seung Won Jung

B.Sc. candidate in the Department of Mechanical and System Engineering, Hongik University.

E-mail: sw1598@naver.com



Tae Yeon Han

B.Sc. candidate in the Department of Mechanical and System Engineering, Hongik University.

E-mail: hgf2970@naver.com